



**Prediksi Anomali Termal pada Environment Monitoring System
Server Menggunakan Algoritma Long Short-Term Memory**

SKRIPSI

Sebagai salah satu syarat untuk meraih
Gelar Sarjana

Oleh:

Gamaliel Aradeya
32220076

Universitas Bunda Mulia
Fakultas Teknologi dan Desain
Program Studi Informatika
Jakarta 2025

IDENTITAS PENULIS

Nama : Gamaliel Aradeya
NIM : 32220076
Tempat/tgl lahir : Jakarta, 30 April 2003
Jenis Kelamin : Pria / ~~Wanita~~
Alamat : Sarusunawa Tower D Lantai 10 No 3,Pluit Penjaringan
Jakarta Utara RT/RW 007/006
No. Telp : +62 851 7247 6678
E-mail : gamaliel.aradeyay@gmail.com

Riwayat Pendidikan

Tahun 2009 - 2015 : SDS Genesaret, Jakarta
Tahun 2015 - 2016 : SMPN 21 Jakarta, Jakarta
Tahun 2016 - 2018 : SMPN 1 Tirtoyudo, Malang
Tahun 2018 - 2021 : SMKN 56 Jakarta, Jakarta
Tahun 2022 - sekarang : Universitas Bunda Mulia, Jakarta

PRAKATA

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Kuasa karena atas kasih karunia-nya, skripsi yang berjudul “*Prediksi Anomali Termal dan Efisiensi PUE dengan Algoritma LSTM pada EMS Server*”. Penyusunan skripsi ini merupakan salah satu syarat untuk memperoleh gelar Sarjana pada jenjang pendidikan Strata Satu (S1).

Dalam penyusunan skripsi ini, hal tersebut tidak lepas dari bantuan, arahan, dan bimbingan oleh banyak pihak yang telah memberi banyak masukan kepada penulis. Oleh karena itu, penulis ingin memberikan ucapan terima kasih kepada semua pihak, khususnya kepada:

1. Bapak **Doddy Surja Bajuadji, M.B.A.**, selaku Rektor Universitas Bunda Mulia.
2. Bapak **Dr. Kandi S.S. Dahlan, M.B.A., Ph.D.**, selaku Wakil Rektor Universitas Bunda Mulia.
3. Bapak **Dr. Fransiskus Adikara, S.Kom., MMSi.**, selaku Dekan Fakultas Teknologi dan Desain.
4. Bapak **Agustinus Fritz Wijaya, S.Kom., M.Cs.**, selaku Ketua Program Studi Teknik Informatika.
5. Bapak **Teady Matius Surya Mulyana, S.Kom., M.Kom.** selaku Dosen Pembimbing Akademik yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan serta arahan kepada penulis.

Demikian, penyusunan skripsi ini penulis hadirkan dengan segala kelebihan dan kekurangan akibat keterbatasan ilmu dan kemampuan yang dimiliki.

Jakarta, 17 Januari 2026

Penulis,

Gamaliel Aradeya

DAFTAR ISI

	Halaman
IDENTITAS PENULIS	2
PRAKATA	3
DAFTAR ISI	5
BAB 1	
PENDAHULUAN	6
1.1. Latar Belakang Permasalahan	6
1.2. Pembatasan Masalah	8
1.3. Rumusan Permasalahan	9
1.4. Tujuan dan Manfaat	9
1.5. Sistematika Penulisan	11
BAB 2	
TINJAUAN PUSTAKA	12
2.1 Kerangka Teori	12
2.1.1 Environment Monitoring System	13
2.1.2 Lingkungan Termal Server dan Sensor Suhu-Kelembaban	14
2.1.3 Data Time-Series pada EMS	15
2.1.4 Pra-pemrosesan Data Time-Series	16
2.1.5 Long Short-Term Memory	17
2.1.6 Prediksi Suhu Lingkungan Server	18
2.1.7 Mekanisme Deteksi Anomali Termal Berbasis Ambang Batas	19
2.1.8 Evaluasi Model Prediksi	20
2.1.9 Baseline Sederhana	21
2.2 Penelitian Terdahulu	22
2.3 Kerangka / Skema Berpikir	26
BAB 3	
ANALISIS DAN PERANCANGAN	28
3.1 Rekayasa Kebutuhan	28
3.2 Pemilihan Metode dan Teknologi	29
3.3 Perancangan Proses	30
3.4 Perancangan Arsitektur Sistem	33
3.5 Perancangan Pengujian	33
Daftar Pustaka Sementara	34

BAB 1

PENDAHULUAN

1.1. Latar Belakang Permasalahan

Perkembangan teknologi informasi mendorong meningkatnya penggunaan perangkat server untuk mendukung berbagai layanan digital, seperti penyimpanan data, aplikasi internal, sistem informasi, serta layanan jaringan. Server yang beroperasi secara terus-menerus menghasilkan panas akibat aktivitas komputasi dan penggunaan perangkat keras dalam jangka waktu panjang. Apabila kondisi termal pada lingkungan server tidak dipantau dengan baik, peningkatan suhu dapat menyebabkan penurunan performa, gangguan stabilitas sistem, bahkan kerusakan pada perangkat keras.

Kondisi lingkungan server menjadi salah satu aspek penting dalam menjaga keberlangsungan operasional sistem. Parameter seperti suhu dan kelembaban perlu dipantau secara berkala karena keduanya dapat memengaruhi kestabilan perangkat elektronik. Suhu yang terlalu tinggi berpotensi menyebabkan thermal throttling, sedangkan kelembaban yang tidak sesuai dapat meningkatkan risiko gangguan pada komponen perangkat. Oleh karena itu, diperlukan sistem pemantauan lingkungan yang mampu merekam kondisi server secara kontinu dan menghasilkan data historis yang dapat dianalisis lebih lanjut.

Environment Monitoring System (EMS) merupakan sistem yang digunakan untuk memantau parameter lingkungan seperti suhu dan kelembaban secara terstruktur. Dalam implementasi sederhana pada lingkungan server testbed

atau ruang server skala kecil, EMS dapat digunakan untuk mengumpulkan data sensor secara periodik, menyimpan data tersebut sebagai data deret waktu, serta menampilkannya melalui dashboard monitoring. Namun, sistem monitoring konvensional umumnya masih bersifat reaktif, yaitu hanya memberikan informasi atau peringatan ketika nilai sensor telah melewati ambang batas tertentu. Pendekatan tersebut belum mampu memberikan prediksi terhadap kemungkinan terjadinya kondisi abnormal sebelum ambang batas benar-benar terlampaui.

Data yang dihasilkan oleh EMS memiliki karakteristik time-series karena setiap nilai sensor tercatat berdasarkan urutan waktu tertentu. Karakteristik ini membuka peluang penerapan metode prediksi untuk mengenali pola perubahan suhu pada lingkungan server. Dengan memanfaatkan data historis, sistem tidak hanya menampilkan kondisi saat ini, tetapi juga dapat memperkirakan kondisi suhu pada periode waktu berikutnya. Prediksi tersebut dapat digunakan sebagai dasar untuk mendeteksi potensi anomali termal secara lebih dini.

Salah satu algoritma yang dapat digunakan untuk pemodelan data time-series adalah Long Short-Term Memory (LSTM). LSTM merupakan salah satu jenis Recurrent Neural Network yang dirancang untuk mempelajari hubungan temporal pada data berurutan. Dalam konteks penelitian ini, LSTM digunakan untuk mempelajari pola historis suhu dan kelembaban yang diperoleh dari EMS, kemudian menghasilkan prediksi suhu pada waktu berikutnya. Hasil prediksi tersebut selanjutnya dibandingkan dengan ambang batas operasional yang telah ditentukan untuk mengklasifikasikan kondisi lingkungan server ke dalam status normal, waspada, atau anomali.

Berdasarkan permasalahan tersebut, penelitian ini berfokus pada prediksi anomali termal pada Environment Monitoring System server menggunakan algoritma Long Short-Term Memory. Penelitian ini diarahkan untuk mengembangkan EMS yang mampu melakukan pemantauan parameter lingkungan server, mengelola data time-series, menerapkan model LSTM untuk prediksi suhu, serta menghasilkan informasi status anomali termal sebagai bentuk early warning bagi administrator atau pengguna sistem.

1.2. Pembatasan Masalah

Agar penelitian lebih terarah dan tidak melebar dari fokus utama, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian dilakukan pada lingkungan server testbed atau ruang server skala kecil-menengah sebagai representasi lingkungan operasional server.
2. Sistem yang dikembangkan merupakan Environment Monitoring System untuk melakukan pemantauan dan analisis data lingkungan, bukan sistem kontrol pendinginan otomatis.
3. Parameter utama yang digunakan dalam penelitian ini adalah suhu dan kelembaban yang diperoleh dari sensor lingkungan.
4. Data yang digunakan berbentuk time-series berdasarkan pencatatan sensor secara periodik.
5. Algoritma yang digunakan untuk prediksi dibatasi pada Long Short-Term Memory.
6. Target prediksi model LSTM adalah suhu lingkungan server pada periode waktu berikutnya.
7. Deteksi anomali termal dilakukan berdasarkan hasil prediksi suhu dan ambang batas operasional yang ditentukan dalam penelitian.
8. Penelitian ini tidak membahas sistem kontrol pendingin otomatis dan optimasi energi, melainkan berfokus pada pemantauan lingkungan server serta prediksi anomali termal.
9. Evaluasi model prediksi dilakukan menggunakan metrik kesalahan prediksi seperti RMSE, MAE, dan MAPE, serta evaluasi status anomali berdasarkan perbandingan antara kondisi aktual dan hasil klasifikasi sistem.

1.3. Rumusan Permasalahan

Berdasarkan latar belakang dan pembatasan masalah yang telah diuraikan, rumusan permasalahan dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengembangkan Environment Monitoring System untuk memantau suhu dan kelembaban pada lingkungan server?
2. Bagaimana mengelola data sensor EMS sebagai data time-series yang dapat digunakan untuk proses prediksi suhu?
3. Bagaimana menerapkan algoritma Long Short-Term Memory untuk memprediksi suhu lingkungan server berdasarkan data historis EMS?
4. Bagaimana menentukan potensi anomali termal berdasarkan hasil prediksi suhu dan ambang batas operasional yang ditetapkan?
5. Bagaimana mengevaluasi performa model LSTM dalam melakukan prediksi suhu dan mendukung deteksi anomali termal pada lingkungan server?

1.4. Tujuan dan Manfaat

1.4.1. Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Mengembangkan Environment Monitoring System untuk memantau suhu dan kelembaban pada lingkungan server secara periodik.
2. Mengelola data hasil pembacaan sensor sebagai data time-series yang dapat digunakan dalam proses pelatihan dan pengujian model prediksi.
3. Menerapkan algoritma Long Short-Term Memory untuk memprediksi suhu lingkungan server berdasarkan data historis yang dikumpulkan oleh EMS.

4. Membangun mekanisme deteksi anomali termal berdasarkan hasil prediksi suhu dan ambang batas operasional yang telah ditentukan.
5. Mengevaluasi performa model prediksi menggunakan metrik RMSE, MAE, MAPE, serta membandingkan hasil prediksi LSTM dengan baseline sederhana dalam mendukung deteksi anomali termal.

1.4.2. Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

- **Manfaat Praktis**

Penelitian ini dapat membantu administrator atau pengguna sistem dalam memantau kondisi lingkungan server secara lebih terstruktur. Dengan adanya prediksi suhu dan status anomali termal, sistem dapat memberikan informasi awal terhadap potensi gangguan termal sebelum kondisi menjadi kritis.

- **Manfaat Akademis**

Penelitian ini dapat menjadi referensi akademik terkait penerapan algoritma Long Short-Term Memory pada data time-series yang berasal dari sistem pemantauan lingkungan. Selain itu, penelitian ini juga dapat menambah kajian mengenai penerapan deep learning pada bidang monitoring infrastruktur server.

- **Manfaat Pengembangan Sistem**

Penelitian ini dapat menjadi dasar pengembangan EMS yang lebih lanjut, misalnya dengan penambahan sensor lain, integrasi notifikasi real-time,

peningkatan akurasi model prediksi, atau pengembangan dashboard monitoring yang lebih lengkap.

1.5. Sistematika Penulisan

Sistematika penulisan skripsi ini disusun berdasarkan jalur perekayasaan pada Program Studi Informatika. Adapun sistematika penulisan dalam penelitian ini adalah sebagai berikut:

BAB 1 Pendahuluan

Bab ini membahas latar belakang permasalahan, pembatasan masalah, rumusan permasalahan, tujuan dan manfaat penelitian, serta sistematika penulisan skripsi.

BAB 2 Tinjauan Pustaka

Bab ini membahas teori-teori yang mendukung penelitian, meliputi Environment Monitoring System, data time-series, anomali termal, algoritma Long Short-Term Memory, penelitian terdahulu, serta kerangka berpikir penelitian.

BAB 3 Analisis dan Perancangan

Bab ini menjelaskan analisis kebutuhan sistem, pemilihan metode dan teknologi, perancangan proses, perancangan sistem atau aplikasi, serta perancangan pengujian yang digunakan dalam penelitian.

BAB 4 Implementasi dan Pengujian

Bab ini membahas implementasi Environment Monitoring System, proses

pengumpulan data sensor, penerapan model LSTM, hasil prediksi suhu, pengujian deteksi anomali termal, serta evaluasi performa sistem.

BAB 5 Penutup

Bab ini berisi simpulan dari hasil penelitian serta saran untuk pengembangan sistem dan penelitian selanjutnya.

BAB 2

TINJAUAN PUSTAKA

2.1 Kerangka Teori

Bab ini membahas teori-teori yang menjadi dasar dalam pengembangan Environment Monitoring System server berbasis prediksi anomali termal menggunakan algoritma Long Short-Term Memory. Pembahasan teori difokuskan pada Environment Monitoring System, parameter suhu dan kelembaban pada lingkungan server, data time-series, pra-pemrosesan data, algoritma Long Short-Term Memory, deteksi anomali termal berbasis ambang batas, evaluasi model prediksi, serta baseline sederhana sebagai pembanding performa model.

2.1.1 Environment Monitoring System

Environment Monitoring System atau EMS merupakan sistem yang digunakan untuk melakukan pemantauan kondisi lingkungan secara berkala

menggunakan perangkat sensor, media komunikasi, sistem penyimpanan data, dan antarmuka pemantauan. Dalam konteks sistem berbasis Internet of Things, EMS dapat dipahami sebagai penerapan konsep IoT karena melibatkan perangkat fisik berupa sensor yang mengumpulkan data dari lingkungan, mengirimkan data tersebut melalui jaringan, kemudian mengolahnya menjadi informasi yang dapat dimanfaatkan oleh pengguna sistem (Gubbi et al., 2013).

Pada lingkungan server, EMS berfungsi untuk memantau parameter lingkungan yang berpengaruh terhadap kestabilan perangkat, seperti suhu dan kelembaban. Parameter tersebut penting karena server beroperasi secara terus-menerus dan menghasilkan panas selama proses komputasi berlangsung. Dalam implementasi sederhana pada server testbed atau ruang server skala kecil-menengah, EMS dapat digunakan untuk membaca data sensor secara periodik, menyimpan hasil pembacaan sebagai data historis, serta menampilkannya melalui dashboard monitoring.

EMS dalam penelitian ini tidak diarahkan sebagai sistem kontrol pendinginan otomatis, melainkan sebagai sistem pemantauan dan analisis data lingkungan. Data yang dikumpulkan oleh EMS menjadi sumber utama untuk proses prediksi suhu dan deteksi potensi anomali termal. Pemantauan suhu dan kelembaban dapat dilakukan menggunakan perangkat gateway seperti Raspberry Pi, sehingga konsep gateway berbasis perangkat kecil cukup relevan untuk diterapkan pada sistem pemantauan lingkungan berskala testbed (Rajkumar, 2025).

Sistem monitoring berbasis sensor juga dapat digunakan untuk membaca kondisi suatu objek dan menghasilkan status sistem berdasarkan data yang diperoleh. Konsep tersebut relevan dengan penelitian ini karena EMS yang dikembangkan tidak hanya menampilkan data sensor, tetapi juga menentukan status kondisi lingkungan berdasarkan hasil prediksi dan ambang batas yang ditentukan (Joshua & Mulyana, 2024).

2.1.2 Lingkungan Termal Server dan Sensor Suhu-Kelembaban

Lingkungan termal server berkaitan dengan kondisi suhu dan kelembaban yang memengaruhi kestabilan perangkat komputasi. Server yang bekerja dalam jangka waktu panjang dapat menghasilkan panas secara terus-menerus. Apabila kondisi panas tersebut tidak dipantau, peningkatan suhu dapat berpotensi menyebabkan penurunan performa, gangguan stabilitas, atau kerusakan perangkat keras.

Suhu menjadi parameter utama dalam penelitian ini karena digunakan sebagai target prediksi model LSTM. Sementara itu, kelembaban digunakan sebagai parameter pendukung karena kondisi kelembaban yang tidak sesuai dapat memengaruhi kestabilan komponen elektronik. Batas operasional suhu dan kelembaban pada lingkungan pemrosesan data dapat mengacu pada pedoman ASHRAE TC 9.9 sebagai dasar dalam memahami kondisi lingkungan server yang aman (ASHRAE Technical Committee 9.9, 2021).

Pada penelitian ini, status termal lingkungan server diklasifikasikan menjadi tiga kondisi, yaitu normal, waspada, dan anomali. Status tersebut ditentukan berdasarkan hasil prediksi suhu dan ambang batas operasional yang ditetapkan dalam penelitian. Karena objek penelitian berupa server testbed atau lingkungan skala kecil-menengah, ambang batas yang digunakan perlu disesuaikan dengan kondisi objek uji, kemampuan sensor, dan skenario pengujian yang dilakukan.

2.1.3 Data Time-Series pada EMS

Data time-series merupakan data yang direkam berdasarkan urutan waktu tertentu. Pada EMS, setiap pembacaan sensor suhu dan kelembaban dicatat bersama timestamp sehingga membentuk data berurutan. Karakteristik data seperti ini penting karena nilai sensor pada suatu waktu dapat memiliki hubungan dengan nilai sensor pada waktu sebelumnya.

Dalam penelitian ini, data suhu dan kelembaban dari EMS digunakan sebagai data time-series untuk membangun model prediksi suhu. Data historis yang dikumpulkan digunakan untuk membentuk pola hubungan antara pembacaan sensor sebelumnya dengan suhu pada periode berikutnya. Strategi machine learning untuk forecasting time-series umumnya dilakukan dengan mengubah data historis menjadi pasangan input dan output agar dapat dipelajari oleh model prediksi (Bontempi et al., 2013).

Dengan memanfaatkan data time-series, sistem monitoring dapat dikembangkan dari pendekatan reaktif menjadi pendekatan prediktif. Sistem

reaktif hanya memberikan peringatan ketika nilai sensor telah melewati ambang batas, sedangkan sistem prediktif dapat memperkirakan kemungkinan perubahan suhu pada waktu berikutnya. Hal ini menjadi dasar penggunaan LSTM dalam penelitian ini.

2.1.4 Pra-pemrosesan Data Time-Series

Pra-pemrosesan data merupakan tahapan penting sebelum data digunakan untuk pelatihan dan pengujian model. Data sensor yang diperoleh dari EMS dapat mengandung nilai kosong, nilai tidak wajar, keterlambatan timestamp, atau pencilaan akibat kesalahan pembacaan sensor. Apabila data tersebut tidak diproses terlebih dahulu, model prediksi berpotensi menghasilkan performa yang kurang akurat.

Tahapan pra-pemrosesan dalam penelitian ini meliputi validasi timestamp, penanganan missing value, deteksi nilai pencilaan, normalisasi data, dan pembentukan window data. Validasi timestamp dilakukan untuk memastikan urutan data sesuai dengan waktu pencatatan. Penanganan missing value dilakukan apabila terdapat data sensor yang tidak terbaca pada periode tertentu. Normalisasi dilakukan agar fitur yang digunakan berada pada skala yang seragam.

Pembentukan window data dilakukan dengan mengambil sejumlah data historis sebagai input untuk memprediksi suhu pada periode berikutnya. Misalnya, data suhu dan kelembaban pada beberapa interval sebelumnya digunakan sebagai masukan untuk memprediksi suhu pada waktu $t+n$. Pendekatan ini sesuai dengan konsep forecasting berbasis supervised learning, yaitu data historis dibentuk

menjadi pasangan input-output untuk kebutuhan pelatihan model (Bontempi et al., 2013).

2.1.5 Long Short-Term Memory

Long Short-Term Memory atau LSTM merupakan salah satu pengembangan dari Recurrent Neural Network yang dirancang untuk mempelajari pola pada data berurutan. LSTM dikembangkan untuk mengatasi keterbatasan RNN konvensional dalam mempelajari dependensi jangka panjang akibat masalah vanishing gradient (Hochreiter & Schmidhuber, 1997).

LSTM memiliki struktur memori yang memungkinkan model menyimpan, memperbarui, dan mengeluarkan informasi melalui mekanisme gerbang. Secara umum, terdapat tiga gerbang utama dalam LSTM, yaitu forget gate, input gate, dan output gate. Forget gate menentukan informasi lama yang perlu dipertahankan atau dihapus. Input gate menentukan informasi baru yang akan dimasukkan ke dalam memori. Output gate menentukan informasi yang akan digunakan sebagai keluaran pada langkah waktu tertentu.

Dalam penelitian ini, LSTM digunakan untuk memprediksi suhu lingkungan server berdasarkan data historis EMS. Fitur masukan yang digunakan adalah data suhu dan kelembaban yang telah melalui tahap pra-pemrosesan. Target prediksi model adalah suhu pada periode waktu berikutnya. Penggunaan LSTM dinilai sesuai karena data EMS bersifat time-series dan memiliki pola temporal yang dapat dipelajari dari data historis.

Penerapan LSTM untuk prediksi suhu pada lingkungan data center telah digunakan dalam penelitian sebelumnya, sehingga pendekatan ini relevan sebagai dasar pemodelan prediksi suhu pada lingkungan server atau server testbed (Kang et al., 2022).

2.1.6 Prediksi Suhu Lingkungan Server

Prediksi suhu merupakan proses memperkirakan nilai suhu pada periode mendatang berdasarkan pola data sebelumnya. Dalam penelitian ini, prediksi suhu dilakukan untuk mendukung deteksi dini potensi anomali termal. Model LSTM dilatih menggunakan data historis suhu dan kelembaban yang diperoleh dari EMS, kemudian menghasilkan nilai prediksi suhu pada waktu berikutnya.

Prediksi suhu memiliki peran penting karena sistem monitoring konvensional umumnya hanya menampilkan kondisi saat ini. Dengan adanya prediksi, sistem dapat memberikan informasi awal apabila suhu diperkirakan akan mendekati atau melewati ambang batas tertentu. Prediksi suhu pada lingkungan data center dapat digunakan untuk mendukung pengelolaan kondisi termal dan mengurangi risiko keterlambatan respons terhadap kenaikan suhu (Wang et al., 2024).

LSTM juga telah digunakan pada penelitian prediksi kualitas udara dan suhu berbasis time-series. Hal tersebut menunjukkan bahwa LSTM dapat digunakan sebagai salah satu pendekatan dalam pemodelan data suhu historis, termasuk untuk mendukung prediksi suhu pada data EMS server testbed (Khumaidi et al., 2020).

2.1.7 Mekanisme Deteksi Anomali Termal Berbasis Ambang Batas

Anomali merupakan kondisi yang menyimpang dari pola normal atau nilai yang diharapkan. Dalam konteks data time-series, anomali dapat muncul sebagai nilai yang terlalu tinggi, perubahan mendadak, atau pola yang tidak sesuai dengan perilaku historis data (Chandola et al., 2009). Pada penelitian ini, anomali difokuskan pada anomali termal, yaitu kondisi ketika suhu lingkungan server berada di luar batas yang telah ditentukan.

Deteksi anomali termal dalam penelitian ini dilakukan menggunakan pendekatan berbasis threshold. Hasil prediksi suhu dari model LSTM dibandingkan dengan ambang batas operasional yang ditetapkan. Apabila nilai prediksi suhu berada pada rentang aman, maka sistem memberikan status normal. Apabila nilai prediksi mendekati batas kritis, sistem memberikan status waspada. Apabila nilai prediksi melewati batas yang ditentukan, sistem memberikan status anomali.

Pendekatan threshold dipilih karena sesuai dengan tujuan penelitian yang ingin menghasilkan mekanisme early warning sederhana dan dapat dijelaskan secara teknis. Deteksi anomali pada data time-series dapat dilakukan melalui berbagai pendekatan, termasuk analisis terhadap nilai aktual, nilai prediksi, residual, atau pelanggaran terhadap batas tertentu (Blazquez-Garcia et al., 2021). Oleh karena itu, penggunaan hasil prediksi suhu dan threshold operasional dapat digunakan sebagai dasar deteksi anomali termal pada EMS.

2.1.8 Evaluasi Model Prediksi

Evaluasi model dilakukan untuk mengukur tingkat kesalahan antara nilai suhu aktual dan nilai suhu hasil prediksi. Dalam penelitian ini, evaluasi model menggunakan Root Mean Square Error, Mean Absolute Error, dan Mean Absolute Percentage Error. Ketiga metrik tersebut umum digunakan dalam evaluasi model forecasting untuk mengukur akurasi hasil prediksi (Hyndman & Koehler, 2006).

Root Mean Square Error atau RMSE digunakan untuk menghitung akar dari rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi. RMSE memberikan penalti lebih besar terhadap kesalahan prediksi yang tinggi, sehingga cocok digunakan untuk melihat sensitivitas model terhadap lonjakan error.

Mean Absolute Error atau MAE digunakan untuk menghitung rata-rata selisih absolut antara nilai aktual dan nilai prediksi. MAE lebih mudah dipahami karena menunjukkan rata-rata besar kesalahan dalam satuan yang sama dengan data asli, yaitu derajat Celsius.

Mean Absolute Percentage Error atau MAPE digunakan untuk mengukur kesalahan prediksi dalam bentuk persentase. MAPE dapat membantu membandingkan tingkat kesalahan model secara relatif. Namun, penggunaan MAPE perlu diperhatikan apabila nilai aktual mendekati nol, karena dapat menghasilkan persentase kesalahan yang terlalu besar.

Selain evaluasi regresi, penelitian ini juga mengevaluasi status anomali yang dihasilkan oleh sistem. Evaluasi status dilakukan dengan membandingkan status hasil sistem dengan kondisi aktual berdasarkan ambang batas yang telah ditentukan. Evaluasi ini penting karena keberhasilan penelitian tidak hanya dilihat

dari kecilnya nilai error prediksi, tetapi juga dari kemampuan sistem dalam mendukung deteksi status normal, waspada, atau anomali.

2.1.9 Baseline Sederhana

Baseline sederhana digunakan sebagai pembandingan untuk menilai apakah model LSTM memberikan nilai tambah dibandingkan metode prediksi dasar. Dalam penelitian time-series, baseline seperti naive forecast, persistence model, atau moving average sering digunakan sebagai pembandingan awal (Hyndman & Athanasopoulos, 2021).

Persistence model merupakan metode sederhana yang menggunakan nilai terakhir sebagai prediksi periode berikutnya. Misalnya, suhu pada waktu t digunakan sebagai prediksi untuk suhu pada waktu $t+1$. Sementara itu, moving average menggunakan rata-rata beberapa data terakhir sebagai nilai prediksi. Kedua metode ini sederhana, tetapi berguna sebagai pembandingan minimum.

Dalam penelitian ini, baseline digunakan untuk membandingkan performa LSTM berdasarkan nilai RMSE, MAE, dan MAPE. Apabila LSTM menghasilkan error yang lebih rendah dibandingkan baseline, maka model LSTM dapat dikatakan memiliki kontribusi yang lebih baik dalam memprediksi suhu lingkungan server. Sebaliknya, apabila performa LSTM tidak lebih baik dari baseline, maka rancangan model, jumlah data, window input, atau proses pra-pemrosesan perlu dievaluasi kembali.

2.2 Penelitian Terdahulu

Penelitian terdahulu digunakan untuk mengetahui posisi penelitian ini dibandingkan dengan penelitian yang telah dilakukan sebelumnya. Pembahasan penelitian terdahulu juga digunakan untuk mengidentifikasi persamaan, perbedaan, serta celah penelitian yang menjadi dasar pengembangan sistem dalam skripsi ini.

Tabel 2.1 Penelitian Terdahulu 1

Keterangan	Isi
Judul	Humidity and temperature monitoring using Raspberry Pi via RS232 networking
Tahun Terbit	2025
Nama Penulis	P. Rajkumar
Jurnal	Array
Kesimpulan	Penelitian ini membahas sistem monitoring suhu dan kelembaban menggunakan Raspberry Pi sebagai perangkat penghubung. Sistem tersebut menunjukkan bahwa perangkat kecil seperti Raspberry Pi dapat digunakan untuk membaca dan mengirim data lingkungan secara periodik.
Persamaan	Sama-sama menggunakan parameter suhu dan kelembaban sebagai data utama dalam sistem pemantauan lingkungan.
Perbedaan	Penelitian Rajkumar berfokus pada monitoring suhu dan kelembaban, sedangkan penelitian ini menambahkan proses prediksi suhu menggunakan LSTM dan penentuan status normal, waspada, atau anomali.

Tabel 2.2 Penelitian Terdahulu 2

Keterangan	Isi
Judul	A two-segment LSTM based data center temperature prediction model
Tahun Terbit	2022
Nama Penulis	Y. Kang, C. Ma, S. Wang, W. Wu, dan K. Zhao
Jurnal	IEICE Electronics Express

Kesimpulan	Penelitian ini membahas penggunaan model LSTM untuk memprediksi suhu pada lingkungan data center. Model yang digunakan diarahkan untuk mempelajari pola suhu berdasarkan data historis sehingga dapat menghasilkan prediksi suhu.
Persamaan	Sama-sama menggunakan LSTM untuk memprediksi suhu pada lingkungan yang berkaitan dengan server atau data center.
Perbedaan	Penelitian Kang et al. berfokus pada pengembangan model prediksi suhu data center, sedangkan penelitian ini berfokus pada perekayasaan EMS server testbed yang mencakup sensor suhu dan kelembaban, penyimpanan data time-series, dashboard, prediksi suhu, dan status anomali termal.

Tabel 2.3 Penelitian Terdahulu 3

Keterangan	Isi
Judul	Data center temperature prediction and management based on a two-stage self-healing model
Tahun Terbit	2024
Nama Penulis	S. Wang, Y. Kang, Y. Xu, C. Ma, H. Wang, dan W. Wu
Jurnal	Simulation Modelling Practice and Theory
Kesimpulan	Penelitian ini membahas prediksi dan pengelolaan suhu pada data center untuk mendukung respons terhadap kondisi termal. Pendekatan prediksi digunakan agar sistem dapat mengantisipasi perubahan suhu secara lebih baik.
Persamaan	Sama-sama menekankan pentingnya prediksi suhu untuk mengurangi risiko keterlambatan respons terhadap kenaikan suhu.
Perbedaan	Penelitian Wang et al. berada pada konteks manajemen suhu data center, sedangkan penelitian ini dibatasi pada EMS server testbed atau ruang server skala kecil-menengah dengan deteksi anomali berbasis threshold.

Tabel 2.4 Penelitian Terdahulu 4

Keterangan	Isi
Judul	Pengujian algoritma Long Short Term Memory untuk prediksi kualitas udara dan suhu Kota Bandung

Tahun Terbit	2020
Nama Penulis	A. Khumaidi, R. Raafi'udin, dan I. P. Solihin
Jurnal	Jurnal Telematika
Kesimpulan	Penelitian ini menerapkan algoritma LSTM untuk memprediksi data kualitas udara dan suhu berbasis time-series. Penelitian tersebut menunjukkan bahwa LSTM dapat digunakan untuk mempelajari pola historis pada data suhu.
Persamaan	Sama-sama menggunakan LSTM untuk memprediksi suhu berdasarkan data historis.
Perbedaan	Objek penelitian Khumaidi et al. adalah suhu dan kualitas udara Kota Bandung, sedangkan penelitian ini berfokus pada suhu lingkungan server dan deteksi anomali termal pada EMS server testbed.

Tabel 2.5 Penelitian Terdahulu 5

Keterangan	Isi
Judul	A review on outlier/anomaly detection in time series data
Tahun Terbit	2021
Nama Penulis	A. Blazquez-Garcia, A. Conde, U. Mori, dan J. A. Lozano
Jurnal	ACM Computing Surveys
Kesimpulan	Penelitian ini membahas berbagai pendekatan deteksi outlier dan anomali pada data time-series. Anomali pada data berurutan dapat dianalisis melalui nilai aktual, hasil prediksi, residual, atau pelanggaran terhadap ambang batas tertentu.
Persamaan	Sama-sama membahas anomali pada data time-series.
Perbedaan	Penelitian Blazquez-Garcia et al. merupakan kajian literatur, sedangkan penelitian ini menerapkan deteksi anomali termal secara langsung pada sistem EMS server testbed.

Tabel 2.6 Penelitian Terdahulu 6

Keterangan	Isi
Judul	Engine health monitoring pada sepeda motor berbasis Arduino menggunakan algoritma Fuzzy Inference System Tsukamoto
Tahun Terbit	2024
Nama Penulis	L. Joshua dan T. M. S. Mulyana
Jurnal	Jurnal Algoritma, Logika dan Komputasi

Kesimpulan	Penelitian ini membahas sistem monitoring berbasis sensor untuk membaca kondisi objek dan menghasilkan status sistem menggunakan pendekatan inferensi fuzzy.
Persamaan	Sama-sama menggunakan data sensor untuk melakukan pemantauan kondisi dan menghasilkan status sistem.
Perbedaan	Penelitian Joshua dan Mulyana berfokus pada engine health monitoring sepeda motor, sedangkan penelitian ini berfokus pada EMS server, prediksi suhu menggunakan LSTM, dan deteksi anomali termal berbasis threshold.

Berdasarkan penelitian terdahulu, dapat disimpulkan bahwa penelitian mengenai monitoring suhu, prediksi suhu, LSTM, dan deteksi anomali time-series telah banyak dilakukan. Namun, penelitian-penelitian tersebut umumnya masih berfokus pada salah satu aspek saja, seperti monitoring suhu, prediksi suhu data center, atau kajian metode deteksi anomali. Penelitian ini memiliki posisi yang lebih spesifik, yaitu mengembangkan Environment Monitoring System pada lingkungan server testbed, mengelola data suhu dan kelembaban sebagai data time-series, menerapkan LSTM untuk memprediksi suhu, serta menggunakan hasil prediksi tersebut sebagai dasar penentuan status normal, waspada, atau anomali.

Dengan demikian, celah penelitian yang diangkat adalah integrasi antara EMS sederhana, prediksi suhu berbasis LSTM, dan deteksi anomali termal berbasis threshold dalam satu alur sistem perekayasaan. Fokus utama penelitian bukan hanya menampilkan data sensor, tetapi juga menghasilkan informasi prediktif yang dapat digunakan sebagai early warning terhadap potensi gangguan termal.

2.3 Kerangka / Skema Berpikir

Kerangka berpikir dalam penelitian ini disusun berdasarkan permasalahan bahwa sistem monitoring lingkungan server umumnya masih bersifat reaktif. Sistem reaktif hanya memberikan informasi atau peringatan ketika suhu telah melewati ambang batas tertentu. Pendekatan tersebut belum cukup untuk mendukung deteksi dini terhadap potensi gangguan termal. Oleh karena itu, penelitian ini mengembangkan EMS yang tidak hanya memantau suhu dan kelembaban, tetapi juga memanfaatkan data historis untuk memprediksi suhu pada periode berikutnya menggunakan LSTM.

Alur penelitian dimulai dari pembacaan suhu dan kelembaban menggunakan sensor pada lingkungan server testbed. Data sensor yang terbaca dikirimkan ke sistem backend dan disimpan sebagai data time-series. Data tersebut kemudian melalui proses pra-pemrosesan, seperti validasi timestamp, penanganan missing value, normalisasi, dan pembentukan window data. Setelah data siap, model LSTM digunakan untuk mempelajari pola historis dan menghasilkan prediksi suhu pada periode waktu berikutnya.

Hasil prediksi suhu kemudian dibandingkan dengan threshold yang telah ditentukan untuk menghasilkan status normal, waspada, atau anomali. Selanjutnya, performa model dievaluasi menggunakan RMSE, MAE, dan MAPE. Hasil prediksi LSTM juga dibandingkan dengan baseline sederhana seperti persistence model atau moving average untuk mengetahui apakah LSTM memberikan performa yang lebih baik.

Secara konseptual, kerangka berpikir penelitian ini dapat dijelaskan sebagai berikut:

Permasalahan:

Monitoring lingkungan server masih bersifat reaktif dan belum mampu memperkirakan potensi kenaikan suhu sebelum melewati ambang batas.

Input:

Data suhu dan kelembaban dari sensor EMS yang dicatat secara periodik.

Proses:

Data sensor disimpan sebagai data time-series, kemudian dilakukan pra-pemrosesan berupa validasi timestamp, penanganan missing value, normalisasi, dan pembentukan window data.

Metode:

Algoritma Long Short-Term Memory digunakan untuk memprediksi suhu lingkungan server pada periode waktu berikutnya berdasarkan data historis.

Deteksi Anomali:

Hasil prediksi suhu dibandingkan dengan threshold untuk menentukan status normal, waspada, atau anomali.

Evaluasi:

Model dievaluasi menggunakan RMSE, MAE, MAPE, evaluasi status anomali, serta perbandingan dengan baseline sederhana.

Hasil yang Diharapkan:

EMS mampu memantau suhu dan kelembaban lingkungan server, menyimpan data time-series, memprediksi suhu menggunakan LSTM, dan memberikan informasi awal terhadap potensi anomali termal.

BAB 3

ANALISIS DAN PERANCANGAN

Bab ini membahas analisis kebutuhan dan perancangan sistem yang dikembangkan dalam penelitian. Sistem yang dirancang merupakan **Environment Monitoring System (EMS)** pada lingkungan **server testbed** yang berfungsi untuk memantau suhu dan kelembaban, menyimpan data sensor sebagai data time-series, melakukan prediksi suhu menggunakan algoritma **Long Short-Term Memory (LSTM)**, serta menentukan status kondisi termal menjadi **normal**, **waspada**, atau **anomali**.

Perancangan sistem dilakukan dengan pendekatan perekayasa karena penelitian tidak hanya berfokus pada analisis data, tetapi juga mencakup perancangan perangkat pemantauan, pengiriman data sensor, penyimpanan data, dashboard monitoring, modul prediksi, serta sistem notifikasi. Dengan demikian, Bab ini disusun untuk menjelaskan kebutuhan sistem, pemilihan metode dan teknologi, perancangan proses, perancangan sistem atau aplikasi, serta perancangan pengujian.

3.1 Rekayasa Kebutuhan

Rekayasa kebutuhan merupakan tahap awal dalam perancangan sistem yang bertujuan untuk mengidentifikasi fitur, komponen, batasan, dan karakteristik sistem yang akan dikembangkan. Pada penelitian ini, rekayasa kebutuhan

dilakukan agar sistem EMS yang dibangun mampu menjalankan fungsi utama, yaitu membaca data suhu dan kelembaban dari lingkungan server testbed, mengirimkan data ke backend, menyimpan data sebagai time-series, melakukan prediksi suhu menggunakan LSTM, dan memberikan status kondisi termal berdasarkan ambang batas operasional.

Sistem yang dikembangkan tidak diarahkan sebagai sistem kontrol pendingin otomatis. Sistem juga tidak diarahkan untuk melakukan optimasi energi secara langsung. Fokus utama sistem adalah pemantauan lingkungan server dan prediksi potensi anomali termal berdasarkan data suhu dan kelembaban yang diperoleh dari sensor.

3.1.1 Kebutuhan Fungsional

Kebutuhan fungsional merupakan kebutuhan yang menjelaskan fungsi utama yang harus dapat dilakukan oleh sistem. Kebutuhan fungsional pada penelitian ini disusun berdasarkan alur kerja sistem, mulai dari pembacaan sensor, pengiriman data, penyimpanan data, prediksi suhu, klasifikasi status, hingga notifikasi.

3.1.1.1 Fungsi Akuisisi Data Sensor

Sistem harus mampu membaca data suhu dan kelembaban dari dua sensor yang ditempatkan pada dua titik berbeda di sekitar server testbed. Penggunaan dua sensor bertujuan agar sistem dapat membandingkan kondisi suhu antara area referensi lingkungan dan area yang lebih dekat dengan sumber panas perangkat.

Sensor pertama, yaitu **S1**, ditempatkan pada area ambient atau referensi ruangan. Sensor ini berfungsi untuk membaca suhu dan kelembaban lingkungan sekitar yang tidak terkena hembusan panas langsung dari perangkat server testbed. Data dari S1 digunakan sebagai pembanding terhadap kondisi suhu pada area utama pemantauan.

Sensor kedua, yaitu **S2**, ditempatkan pada area hotspot atau dekat exhaust laptop/server testbed. Sensor ini menjadi sensor utama karena posisinya paling dekat dengan sumber panas. Oleh karena itu, suhu pada sensor S2 digunakan sebagai target utama prediksi model LSTM. Dengan rancangan ini, S1 berperan sebagai sensor referensi, sedangkan S2 berperan sebagai sensor utama untuk prediksi suhu dan penentuan status termal.

3.1.1.2 Fungsi Pengiriman Data Gateway

Sistem harus mampu mengirimkan data hasil pembacaan sensor dari Raspberry Pi gateway menuju backend. Raspberry Pi berperan sebagai perangkat penghubung antara sensor dan sistem backend.

Sensor membaca suhu dan kelembaban menggunakan komunikasi Modbus RS485. Agar data dari sensor dapat dibaca oleh Raspberry Pi, digunakan USB RS485 Converter sebagai penghubung antara jalur RS485 sensor dan port USB pada Raspberry Pi. Setelah data sensor berhasil dibaca, Raspberry Pi membentuk data dalam format JSON yang berisi identitas sensor, timestamp, suhu, dan

kelembaban. Data tersebut kemudian dikirimkan ke backend menggunakan HTTP REST API.

3.1.1.3 Fungsi Validasi Data Sensor

Backend harus mampu melakukan validasi terhadap data yang diterima dari gateway sebelum data disimpan ke database. Validasi diperlukan untuk mencegah data kosong, data tidak lengkap, atau data tidak logis masuk ke dalam dataset utama.

Validasi data meliputi pengecekan identitas sensor, timestamp, nilai suhu, nilai kelembaban, serta format payload. Apabila data yang diterima tidak valid, sistem mencatat kondisi tersebut sebagai log kesalahan. Apabila data valid, backend melanjutkan proses penyimpanan ke database.

3.1.1.4 Fungsi Penyimpanan Data Time-Series

Sistem harus mampu menyimpan data hasil pembacaan sensor berdasarkan urutan waktu. Data EMS memiliki karakteristik time-series karena setiap pembacaan suhu dan kelembaban dicatat dengan timestamp tertentu. Data historis tersebut diperlukan untuk kebutuhan monitoring, visualisasi grafik, preprocessing, pelatihan model, pengujian model, dan evaluasi prediksi.

Database yang digunakan dalam penelitian ini adalah PostgreSQL dengan dukungan TimescaleDB apabila memungkinkan. PostgreSQL digunakan sebagai basis data utama untuk menyimpan data sensor, hasil prediksi, status anomali, versi model, metrik evaluasi, data layout dashboard, icon status, dan riwayat notifikasi.

TimescaleDB digunakan untuk mendukung pengelolaan data berbasis timestamp yang sesuai dengan karakteristik data time-series.

3.1.1.5 Fungsi Monitoring Dashboard Real-Time

Sistem harus mampu menampilkan data suhu dan kelembaban pada dashboard monitoring. Dashboard digunakan oleh administrator atau pengguna sistem untuk melihat kondisi lingkungan server testbed secara lebih mudah.

Informasi yang ditampilkan pada dashboard meliputi suhu dan kelembaban dari S1 dan S2, grafik perubahan suhu, grafik perubahan kelembaban, status kondisi termal, hasil prediksi suhu S2, metrik evaluasi model, serta riwayat kejadian anomali. Dashboard juga menampilkan indikator status agar pengguna dapat mengetahui apakah kondisi lingkungan berada pada status normal, waspada, atau anomali.

Pengiriman data dari backend ke dashboard dilakukan menggunakan *Server-Sent Events (SSE)*. SSE digunakan karena kebutuhan sistem adalah mengirim pembaruan data satu arah dari backend ke browser secara real-time atau mendekati real-time.

3.1.1.6 Fungsi Visualisasi Layout Sensor

Sistem harus mampu menampilkan posisi sensor pada gambar layout server testbed atau ruangan. Gambar layout digunakan sebagai representasi visual dari posisi perangkat, seperti laptop/server testbed, Raspberry Pi gateway, dan sensor suhu-kelembaban.

Pada dashboard, setiap sensor direpresentasikan menggunakan icon yang menunjukkan status sensor, yaitu normal, waspada, anomali, atau trouble. Status normal, waspada, dan anomali digunakan untuk menunjukkan kondisi termal berdasarkan hasil prediksi dan threshold. Sementara itu, status trouble digunakan untuk menunjukkan masalah operasional sensor, seperti sensor tidak terbaca, timeout, atau data tidak valid.

Fitur visualisasi layout sensor memungkinkan pengguna mengunggah gambar layout server testbed atau ruangan, lalu menempatkan icon sensor pada posisi yang sesuai. Apabila sensor berada pada kondisi waspada, anomali, atau trouble, dashboard menyorot posisi sensor tersebut agar pengguna dapat mengetahui lokasi sumber masalah secara lebih cepat. Fitur ini berfungsi sebagai pendukung visualisasi monitoring dan tidak mengubah proses utama prediksi LSTM.

3.1.1.7 Fungsi Pra-pemrosesan Data

Sistem harus memiliki proses pra-pemrosesan data sebelum data digunakan oleh model LSTM. Pra-pemrosesan dilakukan untuk memastikan data sensor yang digunakan dalam proses pelatihan dan pengujian model berada dalam kondisi layak.

Tahapan pra-pemrosesan meliputi validasi timestamp, pengecekan missing value, pengecekan nilai tidak wajar, normalisasi data, dan pembentukan window data. Pembentukan window data dilakukan dengan mengambil sejumlah data historis sebagai input untuk memprediksi suhu pada periode waktu berikutnya.

Data sensor yang berbentuk time-series dapat diolah menjadi pasangan input dan output agar dapat digunakan dalam proses forecasting (Bontempi et al., 2013).

3.1.1.8 Fungsi Prediksi Suhu Menggunakan LSTM

Sistem harus mampu melakukan prediksi suhu menggunakan algoritma **Long Short-Term Memory**. LSTM digunakan karena data suhu dan kelembaban yang dikumpulkan oleh EMS bersifat berurutan dan memiliki hubungan temporal antarwaktu. LSTM dirancang untuk mempelajari dependensi pada data berurutan sehingga sesuai untuk pemodelan data time-series (Hochreiter & Schmidhuber, 1997).

Pada penelitian ini, model LSTM tidak digunakan untuk memprediksi seluruh sensor secara terpisah. Model difokuskan untuk memprediksi suhu S2 karena S2 ditempatkan pada area hotspot atau titik utama pemantauan termal pada server testbed. Data suhu dan kelembaban dari S1 dan S2 digunakan sebagai fitur input, sedangkan target prediksi adalah suhu S2 pada horizon waktu tertentu. Dengan demikian, S1 berperan sebagai sensor referensi lingkungan, sedangkan S2 berperan sebagai sensor utama untuk prediksi dan penentuan status normal, waspada, atau anomali.

3.1.1.9 Fungsi Klasifikasi Status Termal

Sistem harus mampu mengklasifikasikan kondisi termal berdasarkan hasil prediksi suhu. Status yang digunakan dalam penelitian ini adalah **normal**, **waspada**, dan **anomali**.

Klasifikasi status dilakukan dengan membandingkan suhu hasil prediksi terhadap threshold operasional penelitian. Threshold ini digunakan untuk menentukan apakah suhu yang diprediksi masih berada dalam kondisi aman, mendekati batas peringatan, atau telah melewati batas anomali.

Tabel 3.1 Threshold Status Termal

Status	Kriteria Suhu Prediksi S2
Normal	Suhu prediksi S2 < 30°C
Waspada	Suhu prediksi S2 berada pada rentang 30°C sampai 32°C
Anomali	Suhu prediksi S2 > 32°C

Nilai threshold pada Tabel 3.1 digunakan sebagai ambang operasional pada lingkungan server testbed. Nilai tersebut dapat disesuaikan apabila hasil observasi awal menunjukkan bahwa karakter suhu perangkat dan suhu ruangan memiliki rentang yang berbeda. Dengan demikian, threshold tidak diposisikan sebagai standar universal untuk seluruh lingkungan server, tetapi sebagai batas operasional yang digunakan dalam penelitian.

3.1.1.10 Fungsi Notifikasi Telegram

Sistem harus mampu mengirimkan notifikasi melalui Telegram apabila status termal berubah menjadi waspada atau anomali. Notifikasi digunakan sebagai bentuk early warning agar administrator atau pengguna sistem dapat mengetahui potensi gangguan termal tanpa harus terus-menerus membuka dashboard.

Notifikasi Telegram berisi informasi waktu kejadian, sensor acuan, nilai suhu prediksi, status termal, dan pesan peringatan. Untuk menghindari pengiriman pesan secara berulang dalam waktu singkat, sistem dapat menerapkan jeda atau cooldown notifikasi.

3.1.1.11 Fungsi Evaluasi Model dan Baseline

Sistem harus mampu mengevaluasi performa model LSTM menggunakan metrik RMSE, MAE, dan MAPE. Evaluasi dilakukan dengan membandingkan nilai suhu aktual dengan nilai suhu hasil prediksi. Penggunaan metrik evaluasi diperlukan agar performa model dapat dinilai secara kuantitatif.

Selain mengevaluasi LSTM, sistem juga membandingkan hasil prediksi LSTM dengan baseline sederhana, seperti persistence model atau moving average. Baseline digunakan sebagai pembandingan awal agar performa LSTM tidak dinilai secara tunggal. Dalam forecasting, baseline sederhana dapat digunakan untuk melihat apakah model yang lebih kompleks benar-benar memberikan peningkatan performa dibandingkan metode dasar (Hyndman & Athanasopoulos, 2021).

3.1.2 Kebutuhan Non-Fungsional

Kebutuhan non-fungsional menjelaskan karakteristik kualitas sistem yang perlu dipenuhi agar sistem dapat berjalan dengan baik. Kebutuhan non-fungsional pada penelitian ini mencakup kinerja waktu nyata, keandalan pembacaan sensor, integritas data, akurasi prediksi, keamanan dasar API, dan kemudahan penggunaan dashboard.

3.1.2.1 Kinerja Waktu-Nyata

Sistem dirancang untuk melakukan pembacaan data sensor secara periodik dengan interval sampling awal sebesar 1 menit. Interval ini dipilih agar sistem dapat merekam perubahan suhu dan kelembaban secara cukup teratur tanpa menghasilkan beban penyimpanan data yang terlalu besar.

Dashboard diharapkan mampu menampilkan data terbaru secara real-time atau mendekati real-time. Dengan demikian, pengguna dapat memantau perubahan kondisi lingkungan server testbed tanpa harus melakukan refresh halaman secara manual.

3.1.2.2 Keandalan Pembacaan Sensor

Sistem harus mampu menangani kondisi ketika sensor gagal terbaca, timeout, atau menghasilkan nilai yang tidak wajar. Apabila kondisi tersebut terjadi, sistem tidak langsung menggunakan data tersebut sebagai data valid untuk prediksi. Sistem perlu mencatat kegagalan tersebut sebagai log agar dapat ditelusuri pada tahap pengujian.

Keandalan pembacaan sensor penting karena kualitas data sensor akan memengaruhi kualitas data historis, hasil pelatihan model, dan hasil prediksi suhu.

3.1.2.3 Integritas Data Time-Series

Setiap data sensor yang disimpan harus memiliki timestamp, sensor_id, nilai suhu, dan nilai kelembaban. Timestamp digunakan untuk menjaga urutan data, sedangkan sensor_id digunakan untuk membedakan asal data antara S1 dan S2.

Integritas data time-series perlu dijaga karena proses pelatihan LSTM membutuhkan urutan data yang benar. Oleh karena itu, pembagian data untuk training, validasi, dan testing dilakukan secara kronologis, bukan secara acak.

3.1.2.4 Akurasi Prediksi Model

Model LSTM harus dievaluasi menggunakan metrik kesalahan prediksi. Metrik yang digunakan dalam penelitian ini adalah RMSE, MAE, dan MAPE. RMSE digunakan untuk melihat error dengan penalti lebih besar terhadap kesalahan tinggi. MAE digunakan untuk melihat rata-rata kesalahan absolut dalam satuan derajat Celsius. MAPE digunakan untuk melihat persentase kesalahan prediksi.

Akurasi model tidak hanya dilihat dari kecilnya nilai error, tetapi juga dari kemampuan hasil prediksi dalam mendukung penentuan status normal, waspada, dan anomali.

3.1.2.5 Keamanan Dasar API

Endpoint API yang menerima data dari Raspberry Pi perlu memiliki keamanan dasar. Keamanan dasar dapat berupa token sederhana pada header request, pembatasan akses pada jaringan lokal, atau validasi sumber pengiriman data.

Keamanan ini diperlukan agar backend tidak menerima data dari sumber yang tidak dikenal. Hal ini penting karena data yang masuk ke backend akan disimpan sebagai data historis dan berpotensi digunakan dalam proses prediksi.

3.1.2.6 Kemudahan Penggunaan Dashboard

Dashboard harus dirancang agar pengguna dapat memahami kondisi sistem dengan cepat. Informasi utama seperti suhu aktual, kelembaban, suhu prediksi, status termal, grafik, visualisasi layout sensor, dan riwayat notifikasi harus ditampilkan secara jelas.

Status normal, waspada, anomali, dan trouble perlu dibuat mudah dibedakan agar pengguna dapat segera mengetahui kondisi sistem dan lokasi sensor yang perlu diperhatikan.

3.1.3 Kebutuhan Perangkat Keras

Kebutuhan perangkat keras merupakan komponen fisik yang digunakan untuk membangun EMS server testbed. Perangkat keras yang digunakan meliputi server testbed, Raspberry Pi gateway, sensor suhu dan kelembaban, perangkat komunikasi, serta perangkat jaringan.

3.1.3.1 Laptop sebagai Server Testbed

Laptop digunakan sebagai objek uji yang berperan sebagai server testbed. Laptop dipilih karena dapat merepresentasikan perangkat komputasi yang menghasilkan panas selama menjalankan beban kerja tertentu. Beban kerja dapat berupa aktivitas komputasi ringan atau sedang yang aman untuk perangkat.

Lingkungan pengujian menggunakan meja terbuka atau mini testbed platform. Pemilihan lingkungan uji tersebut dilakukan agar implementasi tetap aman, realistis, dan sesuai dengan ruang lingkup penelitian.

3.1.3.2 Raspberry Pi Gateway

Raspberry Pi digunakan sebagai gateway yang menghubungkan sensor dengan backend. Perangkat ini bertugas membaca data dari sensor XY-MD02 melalui USB RS485 Converter, memberikan timestamp, membentuk payload data, dan mengirimkan data ke backend.

Pada penelitian ini, Raspberry Pi tidak digunakan untuk melakukan training model LSTM. Raspberry Pi difokuskan sebagai perangkat akuisisi data dan pengirim data sensor ke backend melalui jaringan lokal.

3.1.3.3 Sensor XY-MD02 S1 Ambient

Sensor XY-MD02 S1 digunakan untuk membaca suhu dan kelembaban lingkungan sekitar. Sensor ini ditempatkan pada area ambient atau referensi ruangan yang tidak terkena hembusan panas langsung dari laptop. Data dari S1 digunakan sebagai pembanding terhadap suhu pada area hotspot.

3.1.3.4 Sensor XY-MD02 S2 Hotspot atau Exhaust

Sensor XY-MD02 S2 ditempatkan pada area hotspot atau dekat exhaust laptop/server testbed. Sensor ini digunakan untuk membaca kenaikan suhu yang terjadi akibat beban kerja pada server testbed. Karena posisinya paling dekat dengan sumber panas, suhu S2 digunakan sebagai target utama prediksi LSTM dan dasar penentuan status termal


3.1.3.5 USB RS485 Converter

USB RS485 Converter digunakan sebagai penghubung antara sensor XY-MD02 dan Raspberry Pi. Sensor XY-MD02 menggunakan komunikasi Modbus RS485, sehingga diperlukan converter agar data sensor dapat dibaca oleh Raspberry Pi melalui antarmuka USB. Komponen ini berperan penting dalam proses akuisisi data karena menjadi jembatan komunikasi antara sensor industri dan gateway.

3.1.3.6 Perangkat Pendukung Komunikasi dan Daya

Perangkat pendukung komunikasi dan daya digunakan untuk memastikan seluruh komponen dapat terhubung dan berjalan stabil selama proses pengujian. Perangkat ini meliputi kabel RS485, kabel USB, adaptor Raspberry Pi, jaringan lokal, serta perangkat pendukung lain yang diperlukan untuk menghubungkan sensor, gateway, backend, dan dashboard.

Gambar 3.1 Tata Letak Sensor pada Server Testbed



3.1.4 Kebutuhan Perangkat Lunak

Kebutuhan perangkat lunak merupakan komponen software yang digunakan untuk membangun sistem EMS, mulai dari gateway, backend, database, model prediksi, dashboard, hingga notifikasi.

3.1.4.1 Sistem Operasi Raspberry Pi

Raspberry Pi menjalankan sistem operasi yang mendukung program pembacaan sensor dan komunikasi jaringan. Program pada Raspberry Pi digunakan untuk membaca sensor XY-MD02 melalui USB RS485 Converter, membentuk payload data, dan mengirimkan data ke backend.

3.1.4.2 Go/Golang Backend

Go/Golang digunakan untuk membangun backend sistem. Backend bertugas menerima data sensor dari Raspberry Pi, melakukan validasi data, menyimpan data ke database, menyediakan API, mengirim data real-time ke dashboard melalui SSE, dan memicu notifikasi Telegram.

Go dipilih karena memiliki performa yang baik untuk membangun service backend, API, dan proses monitoring yang ringan.

3.1.4.3 PostgreSQL dan TimescaleDB

PostgreSQL digunakan sebagai database utama untuk menyimpan data sistem. TimescaleDB digunakan sebagai dukungan tambahan untuk pengelolaan data time-series. Data yang disimpan meliputi data sensor, hasil prediksi, status anomali, versi model, metrik evaluasi, layout dashboard, icon status, dan log notifikasi.

3.1.4.4 Python untuk Model LSTM

Python digunakan untuk membangun modul kecerdasan buatan. Modul ini mencakup preprocessing data, pembentukan window, training model LSTM, testing model, evaluasi RMSE/MAE/MAPE, baseline comparison, dan inferensi prediksi suhu.

Python dipilih karena memiliki ekosistem machine learning yang lengkap dan mendukung library seperti TensorFlow/Keras atau PyTorch.

3.1.4.5 React, Vite, dan Tailwind CSS

React dan Vite digunakan untuk membangun dashboard monitoring. Tailwind CSS digunakan untuk membantu pembuatan antarmuka yang rapi dan responsif.

Dashboard berfungsi untuk menampilkan data sensor, grafik suhu aktual, grafik kelembaban, grafik prediksi, status sistem, metrik evaluasi, visualisasi layout sensor, dan riwayat alert.

3.1.4.6 Chart.js atau ECharts

Chart.js atau ECharts digunakan untuk menampilkan grafik pada dashboard. Grafik yang dibutuhkan meliputi grafik suhu aktual per sensor, grafik kelembaban, grafik suhu aktual dibandingkan prediksi, dan grafik evaluasi model.

3.1.4.7 Telegram Bot API

Telegram Bot API digunakan untuk mengirimkan notifikasi kepada pengguna ketika status sistem berubah menjadi waspada atau anomali. Fitur ini berfungsi sebagai pendukung early warning pada EMS.

3.1.5 Kebutuhan Data

Data yang digunakan dalam penelitian ini adalah data suhu dan kelembaban yang diperoleh dari dua sensor XY-MD02 pada lingkungan server testbed. Data dikumpulkan secara periodik dengan interval sampling awal 1 menit.

Setiap data memiliki atribut minimal berupa timestamp, sensor_id, suhu, dan kelembaban. Data tersebut digunakan untuk monitoring real-time,

penyimpanan historis, preprocessing, training model LSTM, testing model, evaluasi prediksi, dan demo replay.

Target prediksi model adalah suhu S2 pada waktu mendatang. Dalam rancangan awal, window input menggunakan 30 data terakhir. Jika interval sampling adalah 1 menit, maka window tersebut merepresentasikan 30 menit data historis. Prediction horizon yang digunakan adalah 5 menit ke depan.

Tabel 3.2 Kebutuhan Data Model Prediksi

Komponen	Keterangan
Fitur input	Suhu dan kelembaban dari S1 dan S2
Target prediksi	Suhu S2 pada waktu mendatang
Interval sampling	1 menit
Window input	30 data terakhir
Horizon prediksi	5 menit ke depan
Output model	Nilai prediksi suhu S2
Output sistem	Status normal, waspada, atau anomali

3.1.6 Asumsi dan Batasan Implementasi

Agar implementasi sistem tetap sesuai dengan ruang lingkup penelitian, asumsi dan batasan implementasi yang digunakan adalah sebagai berikut:

1. Objek uji berupa laptop atau mini PC yang berperan sebagai server testbed.
2. Lingkungan pengujian berupa meja terbuka atau mini testbed platform.
3. Sistem menggunakan dua sensor suhu dan kelembaban XY-MD02, yaitu S1 dan S2.


4. Sensor S1 digunakan sebagai sensor ambient atau referensi ruangan.
5. Sensor S2 digunakan sebagai target utama prediksi suhu karena berada di area hotspot atau exhaust.
6. Sensor XY-MD02 dibaca oleh Raspberry Pi menggunakan komunikasi Modbus RS485 melalui USB RS485 Converter.
7. Interval sampling awal ditetapkan sebesar 1 menit.
8. Model LSTM digunakan untuk memprediksi suhu S2 pada waktu mendatang.
9. Status termal ditentukan berdasarkan threshold operasional penelitian.
10. Sistem tidak melakukan kontrol otomatis terhadap pendingin, kipas, atau perangkat listrik.
11. Sistem tidak diarahkan untuk melakukan pengukuran PUE aktual.
12. Evaluasi model dilakukan menggunakan RMSE, MAE, MAPE, dan baseline sederhana.
13. Dashboard menyediakan visualisasi grafik, status termal, riwayat anomali, serta layout posisi sensor sebagai fitur pendukung monitoring.

3.2 Pemilihan Metode dan Teknologi

Pemilihan metode dan teknologi dilakukan untuk menentukan pendekatan pengembangan sistem serta komponen teknis yang digunakan dalam penelitian. Karena sistem yang dikembangkan mencakup perangkat keras, gateway, backend, database, model prediksi, dashboard, dan notifikasi, maka pendekatan pengembangan yang digunakan adalah **prototyping**.

Metode prototyping dipilih karena sistem dikembangkan secara bertahap dan membutuhkan proses uji coba berulang. Pada tahap awal, kebutuhan sistem diidentifikasi berdasarkan tujuan penelitian. Setelah itu, rancangan awal sistem dibuat, prototype dikembangkan, kemudian dilakukan pengujian terhadap pembacaan sensor, pengiriman data, penyimpanan database, dashboard, prediksi LSTM, dan notifikasi. Hasil pengujian digunakan untuk memperbaiki sistem hingga diperoleh prototype final.

Gambar 3.2 Tahapan Metode Prototyping



3.2.1 Pemilihan Metode Prototyping

Metode prototyping digunakan karena penelitian ini membutuhkan proses pengembangan sistem secara bertahap. Sistem EMS yang dirancang tidak hanya berupa perangkat lunak, tetapi juga melibatkan perangkat fisik seperti sensor, Raspberry Pi, dan server testbed. Oleh karena itu, pengujian perlu dilakukan secara berulang untuk memastikan pembacaan sensor, pengiriman data, penyimpanan, dashboard, model prediksi, dan notifikasi dapat berjalan sesuai rancangan.

Tahapan prototyping pada penelitian ini terdiri dari:

1. **Pengumpulan kebutuhan**, yaitu menentukan kebutuhan perangkat keras, perangkat lunak, data, dan fungsi sistem.
2. **Perancangan awal**, yaitu membuat rancangan arsitektur, flowchart, database, API, dashboard, dan integrasi LSTM.
3. **Pembuatan prototype**, yaitu membangun sistem awal berdasarkan rancangan.
4. **Pengujian prototype**, yaitu menguji pembacaan sensor, backend, database, dashboard, prediksi, dan notifikasi.
5. **Evaluasi dan perbaikan**, yaitu memperbaiki sistem berdasarkan hasil pengujian.
6. **Prototype final**, yaitu sistem yang telah diperbaiki dan siap diuji pada Bab 4.

3.2.2 Pemilihan Raspberry Pi sebagai Gateway

Raspberry Pi dipilih sebagai gateway karena mampu menjalankan program akuisisi data sensor, terhubung dengan perangkat USB RS485 Converter, serta mengirimkan data ke backend melalui jaringan lokal. Pada sistem ini, Raspberry Pi berfungsi untuk membaca data suhu dan kelembaban dari sensor XY-MD02, membentuk payload data, dan mengirimkan data ke backend menggunakan HTTP REST API.

Raspberry Pi tidak digunakan untuk menjalankan proses training model LSTM. Proses training, evaluasi, dan inferensi model dilakukan menggunakan Python pada sisi sistem pemrosesan data. Pembagian fungsi ini dilakukan agar gateway tetap fokus pada akuisisi data dan komunikasi sensor.

3.2.3 Pemilihan Sensor XY-MD02 dan Modbus RS485

Sensor XY-MD02 dipilih karena mampu membaca suhu dan kelembaban dalam satu perangkat serta mendukung komunikasi Modbus RS485. Komunikasi Modbus RS485 digunakan karena sesuai untuk pembacaan sensor digital dan dapat diterapkan pada sistem monitoring yang membutuhkan komunikasi data secara stabil.

Dalam penelitian ini, dua sensor XY-MD02 digunakan sebagai sumber data utama. Sensor S1 digunakan untuk membaca kondisi ambient atau referensi ruangan, sedangkan sensor S2 digunakan untuk membaca area hotspot atau exhaust server testbed. Data dari S1 dan S2 digunakan sebagai fitur input model, sedangkan suhu S2 digunakan sebagai target prediksi LSTM.

3.2.4 Pemilihan Go sebagai Backend

Go dipilih sebagai bahasa pemrograman backend karena memiliki performa yang baik, ringan, dan cocok untuk membangun API service. Backend Go digunakan untuk menerima data sensor, melakukan validasi data, menyimpan data ke database, menyediakan endpoint API, mengelola SSE, mengelola data layout sensor, dan memicu notifikasi Telegram.

Pemilihan Go juga mendukung pemisahan antara proses monitoring dan proses machine learning. Backend fokus pada penerimaan data dan layanan sistem, sedangkan proses training dan evaluasi model dilakukan menggunakan Python.

3.2.5 Pemilihan PostgreSQL dan TimescaleDB

PostgreSQL dipilih sebagai database utama karena stabil, umum digunakan, dan mendukung penyimpanan data relasional. TimescaleDB digunakan untuk mendukung pengelolaan data berbasis timestamp yang sesuai dengan karakteristik data time-series.

Data sensor yang dikumpulkan secara periodik membutuhkan penyimpanan yang mampu mengelola timestamp, query historis, dan data berurutan. Oleh karena itu, PostgreSQL dengan dukungan TimescaleDB

digunakan untuk menyimpan data sensor, hasil prediksi, status anomali, metrik evaluasi, versi model, data layout sensor, icon status, dan log notifikasi.

3.2.6 Pemilihan Python untuk LSTM

Python dipilih untuk pengembangan model LSTM karena memiliki library machine learning yang lengkap. Proses preprocessing, pembentukan window, training, testing, evaluasi model, dan baseline lebih mudah dilakukan menggunakan Python.

Pada penelitian ini, Python digunakan sebagai bagian dari intelligence layer. Modul Python mengambil data historis dari database, melakukan preprocessing, melatih model LSTM, mengevaluasi performa model, menghasilkan prediksi suhu S2, dan menyimpan hasil prediksi serta metrik evaluasi ke database.

3.2.7 Pemilihan Server-Sent Events

Server-Sent Events digunakan untuk mengirimkan pembaruan data dari backend ke dashboard. SSE dipilih karena kebutuhan sistem adalah komunikasi satu arah dari server ke browser. Ketika data sensor terbaru atau status terbaru tersedia, backend dapat mengirimkan update ke dashboard tanpa harus menunggu pengguna melakukan refresh halaman.

3.2.8 Pemilihan Telegram Bot API

Telegram Bot API dipilih sebagai media notifikasi karena dapat mengirimkan pesan langsung kepada pengguna. Notifikasi Telegram digunakan ketika status termal berada pada kondisi waspada atau anomali.

Dengan adanya Telegram alert, sistem tidak hanya menampilkan informasi pada dashboard, tetapi juga mampu memberikan peringatan secara langsung kepada administrator atau pengguna sistem.

3.2.9 Pemilihan Baseline Sederhana

Baseline sederhana digunakan sebagai pembanding performa LSTM. Baseline yang digunakan dapat berupa persistence model atau moving average. Persistence model menggunakan nilai suhu terakhir sebagai prediksi suhu berikutnya, sedangkan moving average menggunakan rata-rata beberapa data terakhir sebagai nilai prediksi.


Baseline diperlukan agar hasil LSTM dapat dievaluasi secara objektif. Apabila LSTM menghasilkan nilai error yang lebih rendah dibandingkan baseline, maka LSTM dapat dinilai memberikan kontribusi yang lebih baik dalam prediksi suhu.

3.3 Perancangan Proses

Perancangan proses menjelaskan alur kerja sistem dari pembacaan sensor hingga keluaran berupa dashboard monitoring, prediksi suhu, status anomali, visualisasi layout sensor, dan notifikasi Telegram.

Secara umum, proses sistem dimulai dari pembacaan sensor oleh Raspberry Pi gateway. Data sensor kemudian dikirim ke backend Go untuk divalidasi dan disimpan ke database. Data historis yang terkumpul digunakan oleh modul Python untuk preprocessing, training, evaluasi, dan inferensi model LSTM. Hasil prediksi dibandingkan dengan threshold untuk menentukan status normal, waspada, atau anomali. Status tersebut kemudian ditampilkan pada dashboard, divisualisasikan melalui icon sensor pada layout, dan dikirimkan melalui Telegram apabila memenuhi kondisi peringatan.

Gambar 3.3 Flowchart Proses Utama EMS




3.3.1 Proses Akuisisi Data Sensor

Proses akuisisi data dimulai ketika Raspberry Pi membaca data dari sensor XY-MD02 S1 dan S2 melalui komunikasi Modbus RS485. Sensor S1 membaca suhu dan kelembaban pada area ambient atau referensi ruangan, sedangkan sensor

S2 membaca suhu dan kelembaban pada area hotspot atau dekat exhaust server testbed.

Data dari sensor dibaca melalui USB RS485 Converter yang terhubung ke Raspberry Pi. Setiap data yang berhasil dibaca diberi timestamp agar dapat disimpan sebagai data time-series. Apabila sensor gagal terbaca atau menghasilkan nilai yang tidak wajar, sistem mencatat kondisi tersebut sebagai error dan tidak menggunakan data tersebut sebagai data valid. Apabila data berhasil dibaca, Raspberry Pi membentuk payload data yang berisi sensor_id, timestamp, suhu, dan kelembaban untuk dikirimkan ke backend.

Gambar 3.4 Flowchart Akuisisi Data Sensor



3.3.2 Proses Pengiriman Data Gateway ke Backend

Setelah payload terbentuk, Raspberry Pi mengirimkan data ke backend menggunakan HTTP POST. Endpoint yang digunakan adalah /api/readings. Backend menerima data tersebut dan melakukan validasi awal.

Apabila data tidak sesuai format, backend mengembalikan respons error. Apabila data sesuai format, backend melanjutkan proses penyimpanan data ke database.

Contoh payload data sensor adalah sebagai berikut:

```
{
  "sensor_id": "S2",
  "timestamp": "2026-05-16T10:15:00+07:00",
  "temperature": 31.2,
  "humidity": 58.4
}
```

Field sensor_id digunakan untuk membedakan sensor S1, dan S2 Field timestamp digunakan sebagai penanda waktu pembacaan data. Field temperature dan humidity digunakan sebagai nilai hasil pembacaan sensor.

3.3.3 Proses Penyimpanan Data Time-Series

Data sensor yang telah divalidasi disimpan ke tabel sensor_readings. Setiap data disimpan berdasarkan timestamp dan sensor_id. Struktur penyimpanan

ini memungkinkan sistem mengambil data historis berdasarkan rentang waktu tertentu.


Data historis yang tersimpan digunakan untuk dua kebutuhan utama. Pertama, data digunakan untuk visualisasi dashboard. Kedua, data digunakan sebagai dataset untuk preprocessing, pelatihan model LSTM, pengujian model, dan evaluasi model.

3.3.4 Proses Pra-pemrosesan Data

Pra-pemrosesan dilakukan sebelum data digunakan dalam model LSTM. Proses ini dimulai dengan mengambil data historis dari database. Data kemudian diurutkan berdasarkan timestamp untuk memastikan urutan waktu benar.

Selanjutnya, sistem memeriksa missing value, nilai tidak wajar, dan konsistensi interval data. Setelah itu, data dinormalisasi agar skala fitur menjadi seragam. Data yang telah dinormalisasi kemudian dibentuk menjadi window input. Pada rancangan awal, window input menggunakan 30 data terakhir untuk memprediksi suhu S2 pada 5 menit ke depan.

Gambar 3.5 Flowchart Pra-pemrosesan Data dan Pembentukan Window



3.3.5 Proses Training dan Evaluasi LSTM

Proses training dilakukan menggunakan data historis yang telah melalui tahap pra-pemrosesan. Data dibagi menjadi data training, validasi, dan testing secara kronologis. Pembagian data secara kronologis digunakan karena data time-series memiliki urutan waktu yang tidak boleh diacak.

Model LSTM mempelajari pola historis suhu dan kelembaban dari S1 dan S2. Target prediksi adalah suhu S2 pada waktu mendatang. Setelah model dilatih,

model diuji menggunakan data testing. Hasil prediksi dibandingkan dengan nilai aktual untuk menghitung RMSE, MAE, dan MAPE.

Selain itu, hasil LSTM dibandingkan dengan baseline sederhana. Perbandingan ini digunakan untuk mengetahui apakah LSTM memiliki performa prediksi yang lebih baik dibandingkan metode dasar.

3.3.6 Proses Inferensi Prediksi Suhu

Proses inferensi dilakukan dengan mengambil data terbaru dari database sesuai jumlah window yang dibutuhkan. Data terbaru tersebut diproses menggunakan model LSTM yang telah dilatih. Output dari proses inferensi adalah nilai prediksi suhu S2 pada horizon waktu tertentu.


Hasil prediksi kemudian disimpan ke tabel *predictions* agar dapat ditampilkan pada dashboard dan digunakan dalam proses klasifikasi status termal.

3.3.7 Proses Klasifikasi Status Termal

Setelah nilai suhu prediksi diperoleh, sistem membandingkan nilai tersebut dengan threshold yang telah ditentukan. Apabila suhu prediksi berada di bawah 30°C, sistem memberikan status normal. Apabila suhu prediksi berada pada rentang 30°C sampai 32°C, sistem memberikan status waspada. Apabila suhu prediksi berada di atas 32°C, sistem memberikan status anomali.

Status yang dihasilkan disimpan ke tabel *anomaly_events*. Status tersebut juga ditampilkan pada dashboard. Apabila status adalah waspada atau anomali, sistem mengirimkan notifikasi Telegram.

Gambar 3.6 Flowchart Klasifikasi Status dan Telegram Alert



3.3.8 Proses Monitoring Dashboard dan Layout Sensor

Dashboard mengambil data terbaru dari backend dan menampilkannya dalam bentuk kartu informasi, grafik, tabel riwayat, serta layout sensor. Data yang ditampilkan meliputi suhu dan kelembaban setiap sensor, grafik suhu aktual, grafik aktual versus prediksi S2, status termal, metrik evaluasi model, riwayat notifikasi, dan posisi sensor pada layout.

Pada fitur visualisasi layout, pengguna dapat menampilkan gambar server testbed atau ruangan sebagai latar. Icon sensor kemudian ditempatkan pada posisi tertentu sesuai lokasi sensor. Ketika status sensor berubah menjadi normal, waspada, anomali, atau trouble, tampilan icon ikut berubah. Dengan demikian, dashboard tidak hanya menampilkan data numerik, tetapi juga memberikan representasi visual lokasi sensor yang mengalami kondisi tidak normal.


Dashboard menerima update real-time menggunakan SSE, sehingga pengguna dapat melihat perubahan kondisi sistem tanpa melakukan refresh halaman.

3.4 Perancangan Sistem/Aplikasi

Perancangan sistem menjelaskan struktur teknis aplikasi yang dikembangkan. Sistem EMS dalam penelitian ini dibagi menjadi beberapa lapisan, yaitu sensor layer, gateway layer, backend layer, database layer, intelligence layer, serta presentation and notification layer.

Sensor layer terdiri dari dua sensor XY-MD02 yang membaca suhu dan kelembaban pada area ambient dan hotspot. Gateway layer dijalankan oleh Raspberry Pi yang membaca data sensor melalui USB RS485 Converter. Backend layer dikembangkan menggunakan Go untuk menerima data, melakukan validasi, menyediakan API, mengelola SSE, mengelola data layout sensor, serta memicu notifikasi Telegram. Database layer menggunakan PostgreSQL dengan dukungan TimescaleDB untuk menyimpan data sensor, hasil prediksi, status anomali, versi model, metrik evaluasi, layout sensor, icon status, dan log notifikasi. Intelligence layer menggunakan Python untuk preprocessing, training, evaluasi, baseline, dan inferensi LSTM. Presentation and notification layer terdiri dari dashboard monitoring, visualisasi layout sensor, grafik prediksi, serta Telegram alert.

Gambar 3.7 Arsitektur Sistem EMS Berbasis LSTM



3.4.1 Sensor Layer

Sensor layer merupakan lapisan yang bertugas mengambil data lingkungan dari server testbed. Lapisan ini terdiri dari dua sensor XY-MD02, yaitu S1 dan S2. Sensor S1 membaca suhu dan kelembaban pada area ambient, sedangkan sensor S2 membaca suhu dan kelembaban pada area hotspot atau dekat exhaust.

Sensor layer menghasilkan data suhu dan kelembaban yang menjadi input utama sistem EMS. Data tersebut kemudian diteruskan ke gateway melalui komunikasi Modbus RS485.

3.4.2 Gateway Layer

Gateway layer dijalankan oleh Raspberry Pi. Lapisan ini bertugas membaca data dari sensor, memberikan timestamp, membentuk payload data, dan mengirimkan data ke backend.

Raspberry Pi membaca data sensor XY-MD02 melalui USB RS485 Converter. Data yang berhasil dibaca kemudian dikirim ke backend menggunakan HTTP REST API. Dengan pembagian ini, Raspberry Pi berfungsi sebagai jembatan antara perangkat sensor dan sistem backend.

3.4.3 Backend Layer

Backend layer dikembangkan menggunakan Go. Backend berfungsi sebagai pusat pengelolaan data masuk dari gateway. Backend menerima payload sensor, melakukan validasi, menyimpan data ke database, menyediakan API untuk dashboard, mengirim data melalui SSE, mengelola data layout sensor, dan mengirimkan alert Telegram ketika status sistem memenuhi kondisi tertentu.

Backend juga menjadi penghubung antara data sensor yang masuk dengan lapisan database, dashboard, modul prediksi, dan layanan notifikasi.

3.4.4 Database Layer

Database layer digunakan untuk menyimpan data utama yang dihasilkan oleh sistem EMS. Database yang digunakan adalah PostgreSQL dengan dukungan TimescaleDB apabila memungkinkan. Data yang disimpan meliputi data sensor, hasil prediksi, status anomali, informasi versi model, metrik evaluasi, layout sensor, icon status, dan riwayat notifikasi.

Tabel **sensors** digunakan untuk menyimpan identitas sensor yang digunakan pada sistem. Tabel **sensor_readings** digunakan untuk menyimpan data suhu dan kelembaban berdasarkan timestamp. Tabel **model_versions** digunakan untuk menyimpan informasi versi model LSTM yang digunakan, seperti nama model, versi model, algoritma, window input, horizon prediksi, feature set, serta waktu pelatihan model. Tabel **predictions** digunakan untuk menyimpan hasil prediksi suhu S2 yang dihasilkan oleh model tertentu.

Tabel **anomaly_events** digunakan untuk menyimpan status termal berdasarkan hasil prediksi, sedangkan tabel **model_metrics** digunakan untuk menyimpan hasil evaluasi model menggunakan RMSE, MAE, MAPE, dan baseline. Tabel **notification_logs** digunakan untuk menyimpan riwayat pengiriman notifikasi Telegram. Selain itu, tabel **layouts, layout_devices**, dan **status_icons** digunakan untuk mendukung fitur visualisasi layout sensor pada dashboard.


Rancangan tabel utama adalah sebagai berikut:

Tabel 3.3 Rancangan Tabel Database

Tabel	Fungsi
sensors	Menyimpan identitas sensor, tipe sensor, lokasi sensor, dan status sensor.
sensor_readings	Menyimpan data suhu dan kelembaban berdasarkan timestamp.
model_versions	Menyimpan informasi versi model LSTM yang digunakan dalam

	prediksi dan evaluasi.
predictions	Menyimpan hasil prediksi suhu S2 berdasarkan model tertentu.
anomaly_events	Menyimpan status normal, waspada, atau anomali berdasarkan hasil prediksi.
model_metrics	Menyimpan hasil evaluasi RMSE, MAE, MAPE, serta hasil baseline.
notification_logs	Menyimpan riwayat pengiriman notifikasi Telegram.
layouts	Menyimpan gambar layout server testbed atau ruangan.
layout_devices	Menyimpan posisi sensor pada gambar layout.
status_icons	Menyimpan icon atau gif untuk status normal, waspada, anomali, dan trouble.

Gambar 3.8 Entity Relationship Diagram Database EMS



3.4.5 Intelligence Layer

Intelligence layer merupakan lapisan yang menjalankan proses machine learning. Lapisan ini dikembangkan menggunakan Python dan berfungsi untuk melakukan preprocessing, training model LSTM, evaluasi model, baseline comparison, dan inferensi prediksi suhu.

Training model dilakukan menggunakan data historis dari database. Setelah model menghasilkan prediksi, hasil prediksi disimpan kembali ke database agar dapat digunakan oleh dashboard dan modul klasifikasi status. Informasi versi model disimpan pada tabel *model_versions*, sehingga hasil prediksi dan hasil evaluasi dapat ditelusuri berdasarkan model yang digunakan.

3.4.6 Presentation and Notification Layer

Presentation and notification layer terdiri dari dashboard monitoring dan Telegram Bot. Dashboard digunakan untuk menampilkan data sensor, grafik suhu aktual, grafik hasil prediksi, status termal, metrik evaluasi, visualisasi layout sensor, dan riwayat anomali. Telegram Bot digunakan untuk mengirimkan peringatan ketika status sistem berubah menjadi waspada atau anomali.

Dashboard monitoring juga menyediakan fitur visualisasi layout sensor. Fitur ini memungkinkan pengguna menampilkan gambar layout server testbed atau ruangan sebagai latar visual, kemudian menempatkan icon sensor pada posisi yang sesuai. Status icon berubah berdasarkan status sensor, yaitu normal, waspada, anomali, atau trouble. Fitur ini digunakan sebagai pendukung monitoring visual agar pengguna dapat mengetahui posisi sensor yang mengalami kondisi tidak normal secara lebih cepat.

3.4.7 Rancangan API

Backend menyediakan beberapa endpoint untuk mendukung komunikasi antara gateway, dashboard, database, modul prediksi, visualisasi layout sensor, dan notifikasi.

Tabel 3.4 Rancangan API

Method	Endpoint	Fungsi
POST	/api/readings	Menerima data sensor dari Raspberry Pi gateway.
GET	/api/readings/latest	Mengambil data sensor terbaru.
GET	/api/readings/history	Mengambil data historis sensor berdasarkan rentang waktu.
GET	/api/predictions/latest	Mengambil hasil prediksi terbaru.
POST	/api/predictions/run	Menjalankan proses inferensi prediksi.
GET	/api/anomalies	Mengambil riwayat status normal, waspada, dan anomali.
GET	/api/metrics	Mengambil hasil evaluasi model.
GET	/api/events	Menyediakan koneksi SSE untuk dashboard real-time.
GET	/api/layouts/active	Mengambil layout aktif yang ditampilkan pada dashboard.
POST	/api/layouts	Mengunggah atau menyimpan layout baru.
GET	/api/layout-devices	Mengambil posisi sensor pada layout.
POST	/api/layout-devices	Menyimpan atau mengubah posisi sensor pada layout.
GET	/api/status-icons	Mengambil icon status normal, waspada, anomali, dan trouble.
POST	/api/status-icons	Mengunggah icon atau gif status sensor.

3.4.8 Rancangan Integrasi LSTM

Integrasi LSTM dilakukan dengan memisahkan proses machine learning dari backend utama. Backend Go bertugas menerima dan menyimpan data sensor, sedangkan Python bertugas memproses data historis dan menjalankan model LSTM.

Proses integrasi dilakukan dengan cara Python mengambil data historis dari database, menjalankan preprocessing, melakukan prediksi, kemudian menyimpan hasil prediksi kembali ke database. Pendekatan ini dipilih karena proses training dan evaluasi model tidak harus dijalankan langsung di backend Go.

Dengan pemisahan tersebut, backend tetap fokus pada pengelolaan API, database, dashboard, visualisasi layout, dan notifikasi, sedangkan proses machine learning dikelola secara terpisah menggunakan Python.

3.4.9 Rancangan Notifikasi Telegram

Notifikasi Telegram dikirim ketika status sistem berada pada kondisi waspada atau anomali. Format pesan notifikasi dirancang agar mudah dipahami oleh pengguna.

Contoh format pesan:

```
Peringatan EMS Server Testbed  
Status: WASPADA  
Sensor Acuan: S2 - Hotspot/Exhaust  
Prediksi Suhu: 31.4°C  
Horizon Prediksi: 5 menit ke depan  
Waktu: 16-05-2026 10:15
```

Untuk kondisi anomali, status pesan berubah menjadi **ANOMALI**. Sistem juga menyimpan riwayat pengiriman pesan ke tabel **notification_logs**.

3.5 Perancangan Pengujian

Perancangan pengujian dilakukan untuk memastikan setiap komponen sistem berjalan sesuai kebutuhan. Pengujian mencakup pembacaan sensor, gateway, backend, database, dashboard, visualisasi layout sensor, Telegram alert, model LSTM, baseline, dan klasifikasi status anomali.

3.5.1 Pengujian Pembacaan Sensor

Pengujian pembacaan sensor dilakukan untuk memastikan sensor XY-MD02 S1 dan S2 dapat membaca suhu dan kelembaban melalui komunikasi Modbus RS485. Pengujian dilakukan dengan mencatat jumlah data yang berhasil dibaca, jumlah data yang gagal dibaca, serta kesesuaian timestamp dan sensor_id.

Tabel 3.5 Pengujian Pembacaan Sensor

Komponen yang Diuji	Tujuan Pengujian	Indikator Keberhasilan
Sensor XY-MD02 S1	Memastikan sensor ambient membaca suhu dan kelembaban	Data suhu dan kelembaban S1 terbaca sesuai interval
Sensor XY-MD02 S2	Memastikan sensor hotspot membaca suhu dan kelembaban	Data suhu dan kelembaban S2 terbaca sesuai interval
Modbus RS485	Memastikan komunikasi sensor berjalan	Data dapat dibaca melalui USB RS485 Converter
Timestamp	Memastikan setiap data memiliki waktu pencatatan	Setiap data memiliki timestamp

Sensor ID	Memastikan identitas sensor terbaca benar	Data memiliki sensor_id S1 atau S2
-----------	---	------------------------------------

3.5.2 Pengujian Gateway

Pengujian gateway dilakukan untuk memastikan Raspberry Pi dapat membaca data sensor dan mengirimkan data ke backend. Pengujian dilakukan dengan melihat respons backend terhadap data yang dikirimkan gateway.

Tabel 3.6 Pengujian Gateway

Komponen yang Diuji	Tujuan Pengujian	Indikator Keberhasilan
Raspberry Pi Gateway	Mengirim data sensor ke backend	Backend menerima data dengan respons sukses
Payload JSON	Memastikan format data sesuai	Data memiliki sensor_id, timestamp, suhu, dan kelembaban
HTTP POST	Menguji endpoint /api/readings	Data berhasil diterima backend

3.5.3 Pengujian Backend dan Database

Pengujian backend dan database dilakukan untuk memastikan data sensor yang diterima backend dapat disimpan dengan benar ke database.

Tabel 3.7 Pengujian Backend dan Database

Komponen yang Diuji	Tujuan Pengujian	Indikator Keberhasilan
Backend Go	Validasi data sensor	Data valid diterima, data tidak valid ditolak
Database	Penyimpanan data sensor	Data tersimpan pada tabel sensor_readings
Query historis	Mengambil data berdasarkan waktu	Data dapat diambil sesuai rentang timestamp

Model version	Menyimpan informasi versi model	Data versi model tersimpan pada model_versions
Layout sensor	Menyimpan data layout dan posisi sensor	Data layout tersimpan pada layouts dan layout_devices

3.5.4 Pengujian Dashboard Real-Time

Pengujian dashboard dilakukan untuk memastikan data sensor dan status sistem dapat ditampilkan pada dashboard.

Tabel 3.8 Pengujian Dashboard Real-Time

Komponen yang Diuji	Tujuan Pengujian	Indikator Keberhasilan
Dashboard	Menampilkan data sensor	Suhu dan kelembaban S1 dan S2 tampil pada dashboard
Grafik	Menampilkan data historis	Grafik berubah sesuai data yang masuk
Prediksi	Menampilkan prediksi suhu S2	Grafik aktual vs prediksi tampil
SSE	Mengirim update real-time	Dashboard menerima update tanpa refresh manual

3.5.5 Pengujian Visualisasi Layout Sensor

Pengujian visualisasi layout sensor dilakukan untuk memastikan dashboard dapat menampilkan gambar layout server testbed atau ruangan, menampilkan icon sensor pada posisi yang sesuai, serta mengubah tampilan icon berdasarkan status sensor. Pengujian ini diperlukan karena fitur layout digunakan untuk membantu pengguna mengetahui lokasi sensor yang mengalami kondisi tidak normal.

Tabel 3.9 Pengujian Visualisasi Layout Sensor

Skenario	Indikator Keberhasilan
Menampilkan layout server testbed	Gambar layout tampil pada dashboard
Menampilkan icon sensor	Icon S1 dan S2 tampil pada posisi yang sesuai
Mengubah status sensor	Icon berubah sesuai status normal, waspada, anomali, atau trouble
Menyorot sensor bermasalah	Dashboard menandai sensor yang berstatus waspada/anomali/trouble
Mengunggah icon status	Icon/gif status berhasil disimpan dan digunakan pada dashboard

3.5.6 Pengujian Model LSTM

Pengujian model LSTM dilakukan untuk mengetahui kemampuan model dalam memprediksi suhu S2. Evaluasi dilakukan menggunakan data testing yang tidak digunakan dalam proses training.

Tabel 3.10 Metrik Evaluasi Model LSTM

Metrik	Fungsi
RMSE	Mengukur akar rata-rata kuadrat error prediksi
MAE	Mengukur rata-rata error absolut dalam derajat Celsius
MAPE	Mengukur persentase error prediksi

3.5.7 Pengujian Baseline

Pengujian baseline dilakukan untuk membandingkan hasil LSTM dengan metode sederhana. Baseline yang digunakan adalah persistence model dan/atau moving average.

Tabel 3.11 Pengujian Baseline

Model	Tujuan
Persistence Model	Menggunakan nilai suhu terakhir sebagai prediksi berikutnya
Moving Average	Menggunakan rata-rata beberapa data terakhir sebagai prediksi
LSTM	Menggunakan pola historis time-series untuk prediksi suhu

Indikator keberhasilan pengujian ini adalah LSTM memiliki nilai error yang lebih rendah dibandingkan baseline, atau minimal menunjukkan performa yang kompetitif dengan penjelasan teknis yang dapat dipertanggungjawabkan.

3.5.8 Pengujian Klasifikasi Status Termal

Pengujian status termal dilakukan untuk memastikan sistem dapat menentukan status normal, waspada, atau anomali berdasarkan hasil prediksi suhu S2.

Tabel 3.12 Pengujian Klasifikasi Status Termal

Skenario	Suhu Prediksi S2	Status yang Diharapkan
Kondisi normal	< 30°C	Normal
Kondisi mendekati batas	30°C–32°C	Waspada
Kondisi melewati batas	> 32°C	Anomali

Pengujian ini dapat dilakukan menggunakan data live maupun data historis/replay agar skenario waspada dan anomali dapat diuji secara aman.

3.5.9 Pengujian Telegram Alert

Pengujian Telegram alert dilakukan untuk memastikan sistem mengirimkan notifikasi ketika status berubah menjadi waspada atau anomali.

Tabel 3.12 Pengujian Telegram Alert

Skenario	Kondisi	Indikator Keberhasilan
Status normal	Suhu prediksi < 30°C	Tidak ada alert Telegram
Status waspada	Suhu prediksi 30°C–32°C	Telegram mengirim pesan waspada
Status anomali	Suhu prediksi > 32°C	Telegram mengirim pesan anomali
Cooldown alert	Status sama berulang	Sistem tidak mengirim spam notifikasi

3.5.10 Pengujian Demo Sistem

Pengujian demo sistem dilakukan untuk memastikan sistem dapat ditampilkan secara utuh. Demo mencakup live monitoring, visualisasi layout sensor, prediksi LSTM, evaluasi model, simulasi anomali, Telegram alert, dan recovery.

Tabel 3.13 Pengujian Demo Sistem

Mode Demo	Yang Ditampilkan	Tujuan
Live monitoring	Dashboard suhu dan kelembaban S1 dan S2	Membuktikan EMS berjalan
Visualisasi layout	Layout testbed, icon sensor, dan status sensor	Membuktikan posisi sensor dapat dimonitor secara visual
Prediksi LSTM	Grafik aktual vs prediksi suhu S2	Membuktikan modul prediksi bekerja
Evaluasi model	RMSE, MAE, MAPE, baseline	Membuktikan model dievaluasi secara objektif

Simulasi anomali	CPU stress ringan, sensor S2 didekatkan ke area panas, atau replay data	Membuktikan status waspada/anomali muncul
Telegram alert	Pesan peringatan Telegram	Membuktikan fitur notifikasi berjalan
Recovery	Status kembali normal	Membuktikan sistem mencatat perubahan kondisi

Daftar Pustaka Sementara

- ASHRAE Technical Committee 9.9. (2021). *Thermal guidelines for data processing environments* (5th ed.). ASHRAE.
- Blazquez-Garcia, A., Conde, A., Mori, U., & Lozano, J. A. (2021). A review on outlier/anomaly detection in time series data. *ACM Computing Surveys*, 54(3), Article 56. <https://doi.org/10.1145/3444690>
- Bontempi, G., Ben Taieb, S., & Le Borgne, Y.-A. (2013). Machine learning strategies for time series forecasting. In M.-A. Aufaure & E. Zimanyi (Eds.), *Business Intelligence* (pp. 62–77). Springer. https://doi.org/10.1007/978-3-642-36318-4_3
- Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. *ACM Computing Surveys*, 41(3), Article 15. <https://doi.org/10.1145/1541880.1541882>
- Gubbi, J., Buyya, R., Marusic, S., & Palaniswami, M. (2013). Internet of Things (IoT): A vision, architectural elements, and future directions. *Future Generation Computer Systems*, 29(7), 1645–1660. <https://doi.org/10.1016/j.future.2013.01.010>

- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
<https://doi.org/10.1162/neco.1997.9.8.1735>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688.
<https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Joshua, L., & Mulyana, T. M. S. (2024). Engine health monitoring pada sepeda motor berbasis Arduino menggunakan algoritma Fuzzy Inference System Tsukamoto. *Jurnal Algoritma, Logika dan Komputasi*, 7(2), 697–707. <https://doi.org/10.30813/j-alu.v7i2.7765>
- Kang, Y., Ma, C., Wang, S., Wu, W., & Zhao, K. (2022). A two-segment LSTM based data center temperature prediction model. *IEICE Electronics Express*, 19(21), Article 20220291.
<https://doi.org/10.1587/elex.19.20220291>
- Khumaidi, A., Raafi'udin, R., & Solihin, I. P. (2020). Pengujian algoritma Long Short Term Memory untuk prediksi kualitas udara dan suhu Kota Bandung. *Jurnal Telematika*, 15(1), 13–18.
- Rajkumar, P. (2025). Humidity and temperature monitoring using Raspberry Pi via RS232 networking. *Array*, 27, Article 100464.
<https://doi.org/10.1016/j.array.2025.100464>
- Wang, S., Kang, Y., Xu, Y., Ma, C., Wang, H., & Wu, W. (2024). Data center temperature prediction and management based on a two-stage

self-healing model. *Simulation Modelling Practice and Theory*, 132,

Article 102883. <https://doi.org/10.1016/j.simpat.2023.102883>